

Imperfect CSI 下的 LLM + Beamforming + FAS

1. 研究方向

在 **不完美 CSI** 条件下，如何利用 **大语言模型 / Transformer 类模型** 帮助 **Fluid Antenna System** 进行更鲁棒的 **端口选择与波束赋形联合优化**。

本面向多用户 MISO-FAS 下行通信系统，考虑实际场景中 CSI 存在估计误差的问题，提出一种 uncertainty-aware LLM-based robust port selection and beamforming framework，使模型不仅根据估计 CSI 做决策，还能够显式感知 CSI 的不确定性，从而提升真实信道下的 sum-rate、outage 性能和端口选择稳定性。

2. 背景：为什么要把 FAS、Beamforming 和 LLM 结合起来？

Fluid Antenna System 是一种新型可重构天线技术。它的核心思想是：天线不再只固定在一个位置，而是可以在多个候选端口之间动态切换。这样系统就多了一个新的自由度：

不仅可以设计波束赋形，还可以选择“在哪些端口上发射”。

这使 FAS 在多用户通信中具有很大潜力。因为不同端口看到的信道不同，合理选择端口可以改善用户信道条件、降低多用户干扰、提高系统吞吐量。

但是，FAS 也带来了一个新的困难：

端口选择是离散组合优化问题，波束赋形是连续优化问题，二者耦合后问题高度非凸，传统优化方法通常计算复杂度较高。

因此，最近有研究开始尝试使用 LLM 或 Transformer 类模型学习从 CSI 到端口选择和波束赋形的映射。其优势是：训练离线完成后，在线推理速度较快，适合高维复杂系统中的快速决策。

3. 问题：为什么使用 imperfect CSI

已有很多端口选择和波束赋形方法默认 BS 可以获得较准确的 CSI。但在实际系统中，这个假设往往过于理想。

真实无线系统中的 CSI 可能受到以下因素影响：

- 导频噪声；
- 信道估计误差；
- 反馈延迟；
- 信道老化；
- 用户移动；
- 硬件误差；
- 端口间相关性和互耦影响。

因此，BS 实际获得的不是完整真实信道 H ，而是估计信道：

$$\hat{H} = H + E$$

或者：

$$H = \hat{H} + \Delta H$$

其中 ΔH 表示 CSI 误差。

这会导致一个重要问题：

在估计 CSI 上看起来最优的端口和波束，在真实 CSI 下未必最优，甚至可能造成严重多用户干扰。

尤其在 FAS 中，端口选择高度依赖 CSI。如果模型盲目相信 $\hat{H}$ ，就可能选择一些“估计上很强、但真实上不稳定”的端口。

因此，imperfect CSI 下的 FAS 不能只追求 estimated CSI 上的高 sum-rate，而应该追求真实信道不确定性下的鲁棒性能。

4. 现有工作的不足

目前相关研究可以分为几类。

4.1 LLM + FAS + Beamforming

已有工作已经研究了基于 LLM 的 FAS 端口选择与波束赋形。它证明 LLM 可以用于学习高维 CSI 到端口选择和 BF 的映射。

但是，这类工作主要关注理想 CSI 或估计 CSI 下的直接映射，通常没有把 CSI uncertainty 作为核心输入，也没有显式优化真实信道扰动下的鲁棒性能。

因此，我的研究不能简单说“首次做 LLM-FAS”，因为这已经有人做过。

4.2 LLM + FAS + Port Prediction

也有工作使用 LLM 做流体天线端口预测，主要解决用户移动时未来端口位置预测的问题。

这类工作证明 LLM 可以处理 FAS 中的时序信道和端口预测问题，但它的重点不是 imperfect CSI 下的鲁棒端口选择与波束赋形联合设计。

4.3 LLM + FAS + Channel Prediction

还有工作使用 LLM 做 FAS 信道预测，例如面向卫星通信或 OTFS-FAS 链路预测未来 CSI。

这类工作说明 LLM 可以学习复杂 FAS 信道演化规律，但它主要关注 channel prediction，不是直接解决 robust port selection and beamforming。

4.4 Imperfect CSI + FAS 鲁棒优化

已有传统优化方法研究 imperfect CSI 下的 FAS 或 movable antenna 设计，例如 worst-case optimization、stochastic optimization、SCA、AO、GA 等。

但是，这些方法通常需要复杂迭代优化，在线计算开销较高，也没有充分利用 LLM/Transformer 对高维 token 序列的快速建模能力。

5. 我的研究缺口

我的研究缺口可以概括为：

已有 LLM-FAS 工作主要解决理想或估计 CSI 下的端口选择与 BF；已有 imperfect CSI-FAS 工作主要依赖传统鲁棒优化。二者之间仍缺少一个显式建模 CSI uncertainty 的 robust LLM-FAS 框架。

所以我的方向不是简单的：

LLM-FAS + noisy CSI。

而是：

Uncertainty-aware robust LLM-FAS。

核心区别在于：

1. 模型输入不仅包含估计 CSI，还包含 CSI 不确定性信息；
2. 训练目标不是 estimated CSI 上的 rate，而是真实 CSI 扰动下的 robust rate；
3. 模型输出不是完全自由的 BF 矩阵，而是结合 RZF/WMMSE 结构的鲁棒 BF 参数；
4. 端口选择与 BF 可以采用 two-timescale 设计，提高实际部署合理性。

6. 核心研究问题

本研究希望回答以下问题：

问题 1：如何让 LLM 感知 CSI 不确定性？

传统输入通常是：

$$\Re(\hat{H}), \Im(\hat{H})$$

但我希望输入变成：

$$[\Re(\hat{H}), \Im(\hat{H}), \sigma_e^2, \Sigma_e, \rho, G, P]$$

其中：

- $\hat{H}$: 估计 CSI；
- σ_e^2 : CSI 误差方差；
- Σ_e : CSI 误差协方差；
- ρ : 信道时间相关性或可靠性；
- G : FAS 端口几何信息；
- P : 用户 pathloss 或 QoS 信息。

这样模型可以学习：

哪些端口信道强但不可靠，哪些端口信道微弱但更稳定。

问题 2：如何让训练目标体现鲁棒性？

如果只在 $\hat{H}$ 上优化 sum-rate，那么模型很可能 overfit 到估计 CSI。

因此，训练时可以对每个 $\hat{H}$ 采样多个可能真实信道：

$$H^{(m)} = \hat{H} + \Delta H^{(m)}, \quad m = 1, \dots, M$$

然后在这些真实信道样本上计算 sum-rate。

优化目标可以是：

- average true sum-rate;
- worst-case true sum-rate;
- CVaR true sum-rate。

其中我最倾向使用 CVaR，因为它关注最差一部分信道扰动样本，可以同时兼顾鲁棒性和训练稳定性。

问题 3：如何让 LLM 输出符合物理约束的 BF？

直接让 LLM 输出完整复数波束矩阵 W 可能训练不稳定，也缺少物理解释。

因此，更合理的方式是让 LLM 输出：

$$S, \alpha, p_1, \dots, p_K$$

其中：

- S ：选择的 FAS 端口；
- α ：RZF 正则化参数；
- p_k ：用户功率分配。

然后通过 RZF 层生成波束赋形矩阵：

$$W = \eta \hat{H}_S^H (\hat{H}_S \hat{H}_S^H + \alpha I)^{-1} P^{1/2}$$

这种方式有更好的物理解释：

- CSI error 小时， α 可以更接近 ZF；
- CSI error 大时， α 可以变大，使 BF 更保守；
- 模型不需要完全从零学习通信结构，而是在已有物理结构上学习关键参数。


7. 方法框架

我计划提出一个：

Robust Uncertainty-Aware LLM for Fluid Antenna Systems, 简称 RU-LLM-FAS。

整体流程如下：

```
Estimated CSI
+ CSI uncertainty
+ FAS port geometry
+ user/pathloss information
```



模型输入不是单纯的 CSI，而是通信状态 token 序列。
模型输出不是单纯的端口或波束，而是端口选择、功率分配和鲁棒 BF 参数的联合决策。

8. Two-Timescale 设计思路

FAS 的端口选择和波束赋形不一定应该以相同频率更新。

我考虑采用 two-timescale 设计：

慢时间尺度：端口选择

慢尺度输入：

```
statistical CSI
+ pathloss
+ port correlation
+ long-term uncertainty
```

慢尺度输出：

```
active port set S
```

端口选择不应频繁跟随 noisy instantaneous CSI 变化，而应根据长期稳定的空间结构和端口可靠性决定。

快时间尺度：波束赋形

快尺度输入：

```
instantaneous estimated CSI
+ selected port set
+ instantaneous uncertainty level
```

快尺度输出：

```
regularization factor alpha
+ power allocation p
+ beamforming matrix w
```

这样设计的直觉是：

端口选择负责长期空间结构重构，波束赋形负责短期多用户干扰抑制。

这种结构更符合实际系统，也能突出 imperfect CSI 下端口选择稳定性的重要性。

9. 预期创新点

本研究可以形成以下几个创新点。

创新点 1: Uncertainty-Aware CSI Tokenization

提出面向 FAS 的 CSI 不确定性感知 tokenization 方法，将 estimated CSI、CSI error statistics、端口几何结构和用户大尺度信息统一编码为 LLM token。

创新点 2: Risk-Sensitive Robust Training

训练时不是只最大化估计 CSI 下的 rate，而是对多个真实 CSI 扰动样本计算 true sum-rate，并使用 average / worst-case / CVaR 目标进行鲁棒训练。

创新点 3: Robust BF Parameterization

不直接让 LLM 输出完整 BF 矩阵，而是让模型输出 RZF/WMMSE 结构中的关键鲁棒参数，例如正则化系数和功率分配，从而增强物理可解释性和训练稳定性。

创新点 4: Two-Timescale LLM-FAS Decision

将端口选择和 BF 更新拆分到慢、快两个时间尺度，使端口选择更稳定，BF 更新更灵活，适合 imperfect CSI 和动态信道场景。

创新点 5: 真实 CSI 下的鲁棒性能评估

不仅评估 average sum-rate，还评估 outage probability、5%-outage rate、minimum user rate、port selection stability 和 inference latency。

10. 实验设计

系统设置

初始实验可以从简单场景开始：

- Downlink multiuser MISO-FAS;
- 用户数 $K = 4$;

- 候选端口数 $N = 16$ 或 $N = 32$;
- 激活端口数 $n = K$;
- 信道模型: Rayleigh / Rician;
- CSI error level:

$$\eta = \frac{\mathbb{E}\|\Delta H\|_F^2}{\mathbb{E}\|H\|_F^2}$$

可以设置为:

$$\eta \in \{0, 0.01, 0.03, 0.05, 0.1, 0.2\}$$

Baselines

需要和以下方法对比:

1. Random port + RZF;
2. Greedy strongest port + RZF;
3. GA-based port selection + RZF;
4. AO / WMMSE;
5. Robust RZF;
6. Transformer-based method;
7. 原始 LLM-FAS;
8. LLM-FAS + noisy training;
9. Proposed RU-LLM-FAS。

评价指标

不能只看 average sum-rate, 建议使用:

1. true sum-rate;
2. outage probability;
3. 5%-outage rate;
4. minimum user rate;
5. SINR violation probability;
6. port selection stability;
7. inference latency;
8. robustness degradation。

11. 预期结果

如果方法有效, 预期可以观察到:

1. 在 CSI error 增大时, 原始 LLM-FAS 性能明显下降;
2. RU-LLM-FAS 的 true sum-rate 下降更慢;

3. RU-LLM-FAS 的 outage probability 更低;
4. RU-LLM-FAS 的端口选择更稳定;
5. 相比传统 AO / GA / WMMSE 迭代方法, LLM 推理速度更快;
6. ablation 中去除 uncertainty token 或 CVaR loss 后, 鲁棒性明显下降。

12. 这个方向的风险

这个方向也有一些潜在风险。

风险 1: 创新性被认为只是已有 LLM-FAS 的 noisy extension

应对方式:

必须强调 uncertainty-aware token、risk-sensitive loss、robust BF parameterization 和 two-timescale decision, 而不是只做 noisy CSI training。

风险 2: LLM 的必要性被质疑

应对方式:

需要和 MLP、CNN、普通 Transformer、小型 GPT/LoRA 模型进行对比, 证明 LLM-style sequence modeling 在高维用户-端口 token 建模和多任务输出上有优势。

风险 3: 实验不够有说服力

应对方式:

不能只展示 sum-rate vs SNR, 还要展示:

- sum-rate vs CSI error;
- outage vs CSI error;
- port stability;
- ablation;
- inference latency;
- different number of users / ports 的泛化能力。

13. 介绍

我现在想做的是 imperfect CSI 下的 LLM-FAS 鲁棒波束赋形。已有 LLM-FAS 工作已经证明 LLM 可以学习端口选择和 BF, 但是它们更多是在理想 CSI 或直接估计 CSI 上做决策。实际系统里 CSI 是有误差的, 如果模型盲目相信估计 CSI, 可能会选择不稳定端口, 导致真实信道下性能下降。我想做的是让 LLM 显式感知 CSI 不确定性, 把估计 CSI、误差方差、端口几何和用户状态一起 token 化, 并通过 CVaR 或 worst-case true-rate 训练, 让模型输出更鲁棒的端口选择和 BF 参数。这样可以在 CSI error 增大时保持更高的真实 sum-rate、更低 outage 和更稳定的端口选择。

14. 定位

这个方向不是：

首次使用 LLM 做 FAS。

也不是：

首次研究 imperfect CSI 下的 FAS。

而是：

在已有 LLM-FAS 和 imperfect CSI-FAS 鲁棒优化之间，提出一个 uncertainty-aware robust LLM-FAS 联合端口选择与波束赋形框架。

最核心的研究关键词是：

```
Fluid Antenna System
Imperfect CSI
Robust Beamforming
Port Selection
Large Language Model
Uncertainty-Aware Tokenization
Risk-Sensitive Training
CVaR Sum-Rate
Two-Timescale Decision
RZF Parameterization
```

15. 当前可以推进的最小版本

为了快速验证方向，可以先做最小可行版本：

```
K = 4 users
N = 16 candidate ports
n = 4 active ports
Rayleigh channel
Gaussian CSI error
Input = Re(H_hat), Im(H_hat), sigma_e^2, port geometry
Model = small Transformer / GPT2-small + LoRA
Output = port set S, RZF regularization alpha, power allocation p
Loss = CVaR true sum-rate
```

先证明：

在 CSI error 增大时，加入 uncertainty-aware token 和 CVaR robust loss 的模型比普通 LLM-FAS 更稳。

只要这个结果跑通，后续就可以逐步扩展到：

- correlated CSI error;
- channel aging;
- Rician channel;
- more users;
- larger port set;

- two-timescale version;
- WMMSE refinement layer。

16. 总结

本研究的核心价值在于：

把 LLM-FAS 从“理想 CSI 下的高维决策模型”，推进到“imperfect CSI 下的不确定性感知鲁棒决策模型”。

它的主要意义包括：

1. 更贴近真实无线系统；
2. 解决 FAS 对 CSI 误差敏感的问题；
3. 结合 LLM 的序列建模能力和通信物理结构；
4. 提供比传统迭代优化更快的在线推理；
5. 通过 uncertainty-aware 和 risk-sensitive 设计提高鲁棒性。

最终目标是证明：

在不完美 CSI 下，RU-LLM-FAS 可以比普通 LLM-FAS、Transformer、RZF、GA/AO/WMMSE 等方法获得更高真实 sum-rate、更低 outage、更稳定端口选择和更快推理速度。